CDS521 迁移学习实验文档与填写说明

（配套主论文中的实验占位区使用）

为你的最终提交稿配套准备

这份文档是做什么的：主论文已经写好理论与方法综述，但为了拿更高分，建议你补一个**本地可复现的小实验**。这份指南告诉你：做什么实验最稳、怎么跑、要记录哪些结果、主论文里哪些占位区需要替换、以及怎样把结果写得像“高分论文”而不是“作业截图”。

1. 推荐你做的实验方案（最稳、最容易拿分）

推荐主线：用 **ImageNet 预训练的 ResNet-18**（或 ResNet-50）在一个**小目标数据集**上比较 4 种训练策略：

- **A. From Scratch**：随机初始化，从头训练。
- **B. Feature Extraction**：冻结 backbone，只训练最后的分类头。
- **C. Partial Fine-tuning**：解冻最后一个 stage（如 ResNet 的 layer4）和分类头。
- **D. Full Fine-tuning**：全模型微调。

为什么这个方案最好：

- 和课程题目要求完全对齐：能明确展示 **pre-training**、**feature extraction**、**fine-tuning** 的差异。
- 实现成本低，几乎所有本地机器都能做；没有 GPU 也能跑，只是慢一些。
- 很容易写出“分析”，不只是贴一个准确率。
- 你可以自然讨论 **训练时间**、**参数更新规模**、**数据效率**、**性能差异**，这些都是高分点。

不建议你一开始就做的版本：

- 直接上很大的 ViT 或 LLM：配置压力大，容易翻车。
- 一上来做 LoRA/Prompt Tuning：可以作为加分扩展，但不建议作为唯一实验。
- 数据集太大：会导致你时间都花在跑实验，不利于按时交作业。

2. 数据集怎么选

2.1 最推荐的数据集选择

方案 1(最稳):CIFAR-10 的 4–5 个类别子集。例如:`cat`，`dog`，`bird`，`automobile`，`airplane`。理由是:

- 小而标准，容易获取，结果好解释。
- 用 ImageNet 预训练权重来迁移很自然。
- 类别之间既有容易区分的，也有容易混淆的，方便写 error analysis。

方案 2（更有个性）：你自己的小型图片数据集。例如 3–5 类，每类 100–300 张图。优点是更像真实应用；缺点是要自己清洗数据、命名和划分训练/验证/测试集。

2.2 推荐数据划分

- Train / Validation / Test = 70% / 15% / 15%
- 每一类尽量保持数量接近
- 如果总量很小，可以固定随机种子并重复 3 次实验取平均

3. 模型、训练设置与对比表

3.1 统一设置（保证实验公平）

为了让你的比较有说服力，以下项目应尽量保持一致:

- 输入尺寸：224×224
- 数据增强（训练集）：Resize、RandomHorizontalFlip、轻量 RandomCrop / ColorJitter
- 验证/测试：只做 Resize + Normalize
- 优化器：AdamW 或 SGD（二选一即可，不要混着比较）
- 批大小：16 / 32
- 训练轮数：10–20 epochs（小作业完全够用）
- 早停：验证集 3–5 个 epoch 不提升则停止
- 随机种子：固定，例如 42

3.2 推荐超参数起点

设置	可训练部分	学习率起点	说明
From Scratch	全部参数	1e-3 或 3e-4	作为对照组，通常最慢、最吃数据
Feature Extraction	仅分类头	1e-3	最稳定，最容易在小数据下快速收敛
Partial Fine-tuning	layer4 + fc	1e-4	推荐的“中间路线”，通常很好写分析
Full Fine-tuning	全部参数	1e-5 到 5e-5	数据少时可能过拟合，但理论上上限更高

3.3 你最终至少要拿到的结果

- 4 个设置的最佳验证集准确率 / 测试集准确率
- Macro-F1（建议加上，显得更专业）
- 每个设置的 trainable parameters 数量
- 每个 epoch 的平均训练时间（或总训练时间）
- 4–6 张测试样本预测图（最好有对有错）

4. 软件与硬件需求

4.1 最低软件环境

- Python 3.10 或 3.11
- PyTorch
- torchvision
- timm（如果你想额外试 ViT）
- scikit-learn（算 Macro-F1、confusion matrix）
- pandas / numpy / matplotlib / tqdm / Pillow

4.2 硬件建议

- **最低可跑：**CPU
- **推荐：**单张消费级 GPU（如 6GB–12GB 显存）
- **作业够用配置：**ResNet-18 + 小数据集 + 10–20 epoch

经验判断：

- 没有 GPU：做 ResNet-18 就够，不要贪大。

- 有 GPU：可以把 ResNet-18 作为主实验，再做一个可选扩展（如 ViT-B/16 feature extraction 或 VPT）。

5. 你必须保存的表格和图片

5.1 论文里最应该插入的 2 张图 / 2 个表

表 1：主结果表（必须）

Method	Val Acc	Test Acc	Macro-F1	Trainable Params / Time
Scratch	[填]	[填]	[填]	[填]
Feature Extraction	[填]	[填]	[填]	[填]
Partial Fine-tuning	[填]	[填]	[填]	[填]
Full Fine-tuning	[填]	[填]	[填]	[填]

图 1：训练曲线（建议）

- 训练/验证准确率曲线，至少比较 2–4 个设置
- 或者画验证集 loss 曲线

图 2：样本预测图（建议）

- 每张图写上：True Label、Predicted Label、Confidence
- 一定要包含几个错误样本，方便你写误差分析

表 2：解释性分析表（加分）

Setting	Observed behavior	Interpretation
Feature Extraction	[填]	说明冻结特征为何收敛快、为何上限可能有限
Partial Fine-tuning	[填]	说明解冻高层语义特征为何更适合目标任务
Full Fine-tuning	[填]	说明性能是否更高，以及是否出现过拟合
Scratch	[填]	说明小数据条件下为什么从头训练不占优

6. 主论文里哪些地方要替换

主论文已经预留了实验占位框。你在最终提交前，需要把占位框里的文字换成以下内容：

6.1 替换内容 1：结果表

把上面的“表 1：主结果表”插入到主论文实验占位区。

6.2 替换内容 2：预测样本图

插入 1 张预测可视化图（4–6 张样本拼图即可）。

6.3 替换内容 3：英文分析段（可直接改后粘贴）

下面这段你可以直接放进主论文，再把中括号改成你的实际结果：

Draft paragraph for insertion: To validate the theoretical discussion, I compared four training regimes on a small target dataset: training from scratch, feature extraction, partial fine-tuning, and full fine-tuning using an ImageNet-pretrained ResNet-18 backbone. The best test accuracy was achieved by [**method**] with [**xx.x%**], while feature extraction reached [**xx.x%**] with substantially lower computational cost. Compared with training from scratch, pre-training improved both convergence speed and final generalization, supporting the claim that transferred representations are especially useful in low-data settings. Partial fine-tuning offered the best trade-off between flexibility and stability in my setup, suggesting that adapting high-level semantic layers is often sufficient when the target task is related to the source domain.

6.4 替换内容 4：误差分析句子

你还应该在正文补 2–3 句：

- 哪些类别最容易混淆；
- 为什么会混淆（背景、姿态、分辨率、类间相似度）；
- 迁移学习是否改善了这种混淆。

7. 高分写法：你不要只报数字，要解释数字

老师通常不会只看你“有没有跑”，而是看你“会不会分析”。建议你在实验部分这样写：

- **先写现象：**哪个方法最好，哪个方法最快。
- **再写原因：**为什么预训练能帮助小数据任务。
- **再写限制：**如果 full fine-tuning 没有最好，解释是不是数据太少、学习率太大、过拟合、类别差异不够大。
- **最后写结论：**在你的实验里，迁移学习是否优于 scratch，哪个 regime 最划算。

高分分析关键词：

- sample efficiency
- representation reuse
- optimization stability
- overfitting under limited data
- computational efficiency
- transferability of high-level features

8. 如果你还有时间，可以做的加分扩展

- **扩展 1：** 加入 ViT-B/16 的 feature extraction 或 full fine-tuning，对比 CNN 和 Transformer。
- **扩展 2：** 如果你熟悉 prompt tuning / LoRA，可做一个 PEFT 小实验，哪怕只跑 1 个 setting，也能让你的论文更“当前”。
- **扩展 3：** 报告 trainable parameter ratio（可训练参数占总参数比例），这会让你的实验更像论文。
- **扩展 4：** 增加 confusion matrix，写清楚哪些类最难。

9. 迁移学习方法总图（学习用，写论文时也能直接参考）

你主论文里已经覆盖了“当前主流方法家族”，但为了你自己学得更系统，可以把整个领域记成下面这张“方法地图”：

- **实例级迁移**：重加权、样本选择、过滤不相关源数据。
- **特征级迁移**：TCA、CORAL、DANN、MCD 这类 domain adaptation 方法，本质是对齐源域和目标域特征分布。
- **参数级迁移**：最主流。先预训练，再 feature extraction / fine-tuning。
- **自监督迁移**：SimCLR、MAE、DINOv2 这类先学通用表示再迁移。
- **多模态迁移**：CLIP 这类图文对齐模型，支持 zero-shot transfer。
- **PEFT**：Adapter、Prompt Tuning、Prefix Tuning、BitFit、LoRA、QLoRA、DoRA、VPT。
- **元学习 / few-shot**：MAML、ANIL，强调“快速适应新任务”。
- **域泛化 / 测试时适配**：训练时见不到目标域，或只在部署时见到目标域时再适应。
- **可信迁移学习**：把 fairness、privacy、robustness、calibration 一起考虑。

10. 最后的执行清单

在你真正提交前，请按这个顺序检查：

1. 跑完 4 个训练设置；
2. 整理结果表；
3. 保存 1 张训练曲线和 1 张样本预测图；
4. 把主论文占位框替换成你的真实结果；
5. 把姓名、学号补上；
6. 通读一遍英文表述，统一术语：pre-training / feature extraction / fine-tuning / transferability；
7. 最后导出 PDF 再交。

一句话建议：如果你时间有限，就把 **ResNet-18 + 小数据集 + 4 个 regime 比较**做扎实。这个方案最稳、最好写、最容易形成“理论 + 实验 + 分析”闭环，已经足以支撑一篇高质量课程论文。